

ΑΠΑΛΛΑΚΤΙΚΗ ΕΡΓΑΣΙΑ ΘΕΜΑΤΩΝ ΕΠΙΣΤΗΜΗΣ ΔΕΔΟΜΕΝΩΝ

Ονοματεπώνυμο Φοιτητή: Μπαρδάνης Αντώνιος

Αριθμός Μητρώου: Π21110

Ημερομηνία Παράδοσης: 01/09/2025

Περίληψη

Η παρούσα εργασία εξετάζει το πρόβλημα της πρόβλεψης ταχύτητας κυκλοφορίας σε αστικά οδικά δίκτυα, ένα κρίσιμο ζήτημα για τη διαχείριση της κυκλοφοριακής συμφόρησης και την ανάπτυξη ευφυών συστημάτων μεταφορών. Αξιοποιώντας το ανοιχτό σύνολο δεδομένων PEMS-BAY, το οποίο περιέχει μετρήσεις από 325 επαγωγικούς αισθητήρες στην Bay Area της Καλιφόρνια για το πρώτο εξάμηνο του 2017, αναπτύχθηκαν και αξιολογήθηκαν μοντέλα βαθιάς μάθησης.

Η μεθοδολογία περιελάμβανε εκτενή προεπεξεργασία των δεδομένων, συμπεριλαμβανομένου του χειρισμού ελλειπών τιμών, της αφαίρεσης ακραίων τιμών και της κανονικοποίησης, με ιδιαίτερη προσοχή στην αποφυγή διαρροής δεδομένων. Πραγματοποιήθηκε εξερευνητική ανάλυση για την ανάδειξη ημερήσιων και εβδομαδιαίων εποχικών προτύπων. Για την πρόβλεψη, υλοποιήθηκε ένα μοντέλο βασισμένο σε Δίκτυα Μακράς Βραχυπρόθεσμης Μνήμης (LSTM).

Δύο σενάρια πρόβλεψης αξιολογήθηκαν: (α) βραχυπρόθεσμη πρόβλεψη της ταχύτητας για την επόμενη ώρα με ανάλυση πέντε λεπτών και (β) μεσοπρόθεσμη πρόβλεψη για τις επόμενες δώδεκα ώρες με ωριαία ανάλυση. Η απόδοση των μοντέλων μετρήθηκε με τις μετρικές MAE, MAPE, RMSE και R^2 . Τα αποτελέσματα έδειξαν υψηλή ακρίβεια στη βραχυπρόθεσμη πρόβλεψη (π.χ., MAE της τάξης των 2.5-4.5 mph με την απόδοση να μειώνεται αναμενόμενα

όσο αυξάνεται ο χρονικός ορίζοντας. Η μεσοπρόθεσμη πρόβλεψη αποδείχθηκε σημαντικά πιο απαιτητική, επιβεβαιώνοντας τη στοχαστική φύση της κυκλοφορίας σε μεγαλύτερους ορίζοντες. Η εργασία καταδεικνύει τη δυναμική των μοντέλων LSTM για την αποτελεσματική μοντελοποίηση χρονοσειρών κυκλοφοριακών δεδομένων.

Πίνακας Περιεχομένων

1. Εισαγωγή

- 1.1. Το Πρόβλημα της Κυκλοφοριακής Συμφόρησης
- 1.2. Στόχοι της Εργασίας
- 1.3. Δομή της Αναφοράς

2. Ανάλυση και Προεπεξεργασία Δεδομένων

- 2.1. Περιγραφή Συνόλου Δεδομένων PEMS-BAY
- 2.2. Εξερευνητική Ανάλυση Δεδομένων
- 2.3. Προεπεξεργασία Δεδομένων
 - 2.3.1. Χωρισμός Δεδομένων (Train/Validation/Test)
 - 2.3.2. Χειρισμός Ακραίων και Ελλιπών Τιμών
 - 2.3.3. Κανονικοποίηση

3. Μεθοδολογία Μοντελοποίησης

- 3.1. Μηχανική Χαρακτηριστικών (Feature Engineering)
- 3.2. Διαμόρφωση Προβλήματος Πρόβλεψης
- 3.3. Αρχιτεκτονική Μοντέλου LSTM

4. Αποτελέσματα και Αξιολόγηση

- 4.1. Μετρικές Αξιολόγησης
- 4.2. Αποτελέσματα Βραχυπρόθεσμης Πρόβλεψης (1 ώρα)
- 4.3. Αποτελέσματα Μεσοπρόθεσμης Πρόβλεψης (12 ώρες)
- 4.4. Συζήτηση Αποτελεσμάτων

5. Συμπεράσματα και Μελλοντικές Επεκτάσεις

Βιβλιογραφία

Κεφάλαιο 1: Εισαγωγή

1.1 Το Πρόβλημα της Κυκλοφοριακής Συμφόρησης

Η κυκλοφοριακή συμφόρηση αποτελεί ένα από τα σημαντικότερα προβλήματα των σύγχρονων αστικών κέντρων, με σοβαρές οικονομικές, περιβαλλοντικές και κοινωνικές επιπτώσεις. Η καθυστέρηση στις μετακινήσεις οδηγεί σε απώλεια παραγωγικών ωρών, αυξημένη κατανάλωση καυσίμων και εκπομπή ρύπων, καθώς και σε αυξημένο άγχος για τους οδηγούς. Η έγκαιρη και ακριβής πρόβλεψη της κυκλοφορίας είναι θεμελιώδης για την ανάπτυξη Ευφυών Συστημάτων Μεταφορών (ITS), τα οποία μπορούν να παρέχουν δυναμική δρομολόγηση, να προσαρμόζουν τη λειτουργία των φωτεινών σηματοδοτών και να ενημερώνουν τους πολίτες, βελτιώνοντας τη ροή της κυκλοφορίας.

1.2 Στόχοι της Εργασίας

Κύριος στόχος της παρούσας εργασίας είναι η ανάπτυξη και αξιολόγηση ενός μοντέλου βαθιάς μάθησης για την πρόβλεψη της μέσης ταχύτητας κίνησης ανά αισθητήρα σε ένα πολύπλοκο οδικό δίκτυο. Για την επίτευξη αυτού του στόχου, χρησιμοποιήθηκε το σύνολο δεδομένων PEMS-BAY.

Οι επιμέρους στόχοι περιλαμβάνουν:

1. Την προεπεξεργασία και τον καθαρισμό των δεδομένων χρονοσειρών.
2. Την εξερεύνηση των δεδομένων για την αναγνώριση τάσεων και εποχικών μοτίβων.
3. Την κατασκευή ενός μοντέλου LSTM, κατάλληλου για την επεξεργασία δεδομένων ακολουθίας.
4. Την αξιολόγηση του μοντέλου σε δύο διαφορετικά σενάρια:
 - ο **Βραχυπρόθεσμη Πρόβλεψη**: Πρόβλεψη της ταχύτητας για την επόμενη μία ώρα, με χρονικό βήμα πέντε λεπτών.
 - ο **Μεσοπρόθεσμη Πρόβλεψη**: Πρόβλεψη της ταχύτητας για τις επόμενες δώδεκα ώρες, με χρονικό βήμα μίας ώρας.

1.3 Δομή της Αναφοράς

Η αναφορά είναι δομημένη ως εξής: Το Κεφάλαιο 2 περιγράφει το σύνολο δεδομένων και τις μεθόδους προεπεξεργασίας που εφαρμόστηκαν. Το Κεφάλαιο 3 αναλύει τη μεθοδολογία μοντελοποίησης, συμπεριλαμβανομένης της αρχιτεκτονικής του μοντέλου LSTM. Το Κεφάλαιο 4 παρουσιάζει και συζητά τα αποτελέσματα της αξιολόγησης για τα δύο σενάρια πρόβλεψης. Τέλος, το Κεφάλαιο 5 συνοψίζει τα συμπεράσματα και προτείνει κατευθύνσεις για μελλοντική έρευνα.

Κεφάλαιο 2: Ανάλυση και Προεπεξεργασία Δεδομένων

2.1 Περιγραφή Συνόλου Δεδομένων PEMS-BAY

Το σύνολο δεδομένων PEMS-BAY (Li et al., 2018) περιλαμβάνει δεδομένα κυκλοφορίας από 325 επαγωγικούς αισθητήρες (loop detectors) που είναι εγκατεστημένοι στο οδικό δίκτυο της Bay Area, Καλιφόρνια. Για τις ανάγκες της εργασίας, χρησιμοποιήθηκαν δεδομένα από την 1η Ιανουαρίου 2017 έως την 30η Ιουνίου 2017. Οι μετρήσεις καταγράφονται ανά πεντάλεπτα, με αποτέλεσμα 288 χρονικά βήματα ανά ημέρα. Κάθε στήλη στο αρχικό αρχείο αντιστοιχεί στη μέση ταχύτητα (σε μίλια ανά ώρα) που καταγράφηκε από έναν συγκεκριμένο αισθητήρα.

2.2 Εξερευνητική Ανάλυση Δεδομένων

Για την κατανόηση των υποκείμενων προτύπων, πραγματοποιήθηκε εξερευνητική ανάλυση. Η οπτικοποίηση της χρονοσειράς ενός τυχαίου αισθητήρα για μια εβδομάδα (Εικόνα 1) αποκαλύπτει έντονη ημερήσια εποχικότητα. Παρατηρούνται δύο ημερήσιες "βυθίσεις" στην ταχύτητα, οι οποίες αντιστοιχούν στις πρωινές (περίπου 7-9 π.μ.) και απογευματινές (περίπου 4-6 μ.μ.) ώρες αιχμής. Επιπλέον, η κυκλοφορία είναι αισθητά πιο ομαλή και οι ταχύτητες υψηλότερες κατά τη διάρκεια του Σαββατοκύριακου.

```
[8]: # Επιλογή ενός αισθητήρα (π.χ. ο πρώτος)
sensor_id = train_df.columns[0]
```

```
# Οπτικοποίηση για μία εβδομάδα
plt.figure(figsize=(15, 6))
train_df[sensor_id].loc['2017-02-06':'2017-02-12'].plot()
plt.title(f'Ταχύτητα για τον αισθητήρα {sensor_id} (Μία εβδομάδα)')
plt.ylabel('Ταχύτητα (mph)')
plt.xlabel('Ημερομηνία')
plt.grid(True)
plt.show()
```



Εικόνα 1: Ημερήσια και εβδομαδιαία πρότυπα ταχύτητας για τον αισθητήρα 0.


Το διάγραμμα αυτοσυσχέτισης (ACF plot) (Εικόνα 2) επιβεβαιώνει την ισχυρή ημερήσια περιοδικότητα, με τις κορυφές της συσχέτισης να εμφανίζονται σε χρονικές υστερήσεις (lags) που είναι πολλαπλάσια των 288 βημάτων (24 ώρες). Αυτό υποδηλώνει ότι η ταχύτητα σε μια δεδομένη στιγμή είναι ισχυρά συσχετισμένη με την ταχύτητα την ίδια ώρα την προηγούμενη ημέρα.

```
[ ]: # 2. Διάγραμμα Αυτο-συσχέτισης (Autocorrelation Plot - ACF)
```

```
[9]: # Η ημέρα έχει 24 * 12 = 288 χρονικά βήματα (5-λεπτα)
lags = 288 * 2 # Δύο ημέρες
```

```
plt.figure(figsize=(15, 6))
plot_acf(train_df[sensor_id], lags=lags, title=f'Autocorrelation (ACF) - Sensor {sensor_id}')
plt.xlabel('Καθυστέρηση (Lag) σε 5-λεπτα διαστήματα')
plt.ylabel('Auto-συσχέτιση')
plt.grid(True)
plt.show()
```

<Figure size 1500x600 with 0 Axes>



Εικόνα 2: Διάγραμμα αυτοσυσχέτισης (ACF) για τον αισθητήρα 0.

2.3 Προεπεξεργασία Δεδομένων

Η ποιότητα των δεδομένων είναι κρίσιμη για την απόδοση του μοντέλου.

Ακολουθήθηκαν τα παρακάτω βήματα:

Για την αποφυγή διαρροής δεδομένων (data leakage), ο διαχωρισμός έγινε χρονολογικά πριν από οποιαδήποτε άλλη επεξεργασία:

- **Σύνολο Εκπαίδευσης (Training Set):** 1/1/2017 – 31/3/2017
- **Σύνολο Επικύρωσης (Validation Set):** 1/4/2017 – 30/4/2017
- **Σύνολο Δοκιμής (Test Set):** 1/5/2017 – 30/6/2017

Οι ελλιπείς τιμές (NaNs), που πιθανώς οφείλονται σε δυσλειτουργίες των αισθητήρων, αντιμετωπίστηκαν με γραμμική χρονική παρεμβολή (`interpolate(method='time')`). Τυχόν εναπομείνουσες ελλιπείς τιμές στην αρχή των συνόλων συμπληρώθηκαν με τη μέθοδο `bfill`. Οι ακραίες τιμές (π.χ. μη ρεαλιστικά υψηλές ταχύτητες) περιορίστηκαν σε ένα λογικό εύρος $[0, 100]$ mph μέσω της τεχνικής `clipping`.

Τα μοντέλα νευρωνικών δικτύων αποδίδουν καλύτερα όταν τα δεδομένα εισόδου είναι κανονικοποιημένα. Χρησιμοποιήθηκε ο `MinMaxScaler` της βιβλιοθήκης `Scikit-learn` για τη μετατροπή των τιμών στο εύρος $[0, 1]$. Είναι κρίσιμο να τονιστεί ότι ο `scaler` "εκπαιδεύτηκε" (`fit`) **αποκλειστικά** στο σύνολο εκπαίδευσης και στη συνέχεια εφαρμόστηκε (`transform`) και στα τρία σύνολα (`train`, `validation`, `test`).

Κεφάλαιο 3: Μεθοδολογία Μοντελοποίησης

3.1 Μηχανική Χαρακτηριστικών (Feature Engineering)

Για την ενίσχυση της προβλεπτικής ικανότητας του μοντέλου, τα δεδομένα εμπλουτίστηκαν με νέα χαρακτηριστικά (`features`) που προέκυψαν από τη χρονοσφραγίδα:

- **Ώρα της ημέρας (0-23)**
- **Ημέρα της εβδομάδας (0-6)**
- **Κατηγορική μεταβλητή για το Σαββατοκύριακο** (1 για Σ/Κ, 0 για καθημερινή)

- **Κατηγορική μεταβλητή για τις επίσημες αργίες**

Αυτά τα χαρακτηριστικά βοηθούν το μοντέλο να διακρίνει ρητά τα διαφορετικά κυκλοφοριακά μοτίβα που παρατηρήθηκαν στην εξερευνητική ανάλυση.

3.2 Διαμόρφωση Προβλήματος Πρόβλεψης

Το πρόβλημα της πρόβλεψης χρονοσειρών μετατράπηκε σε πρόβλημα επιβλεπόμενης μάθησης με τη μέθοδο του "ολισθαίνοντος παραθύρου" (sliding window).

- **Βραχυπρόθεσμη Πρόβλεψη:** Ως είσοδος (X) χρησιμοποιήθηκε ένα παράθυρο 12 συνεχόμενων παρατηρήσεων (1 ώρα). Ως έξοδος (Y) ορίστηκαν οι επόμενες 12 παρατηρήσεις (πρόβλεψη για την επόμενη ώρα ανά 5 λεπτά).
- **Μεσοπρόθεσμη Πρόβλεψη:** Ως είσοδος (X) χρησιμοποιήθηκε ένα παράθυρο 24 παρατηρήσεων (2 ώρες). Ως έξοδος (Y) ορίστηκαν 12 παρατηρήσεις, οι οποίες όμως απείχαν μεταξύ τους 12 βήματα (1 ώρα). Δηλαδή, το μοντέλο καλούνταν να προβλέψει την ταχύτητα στις χρονικές στιγμές $t+1h$, $t+2h$, ..., $t+12h$.

3.3 Αρχιτεκτονική Μοντέλου LSTM

Επιλέχθηκε ένα μοντέλο βασισμένο σε Δίκτυα Μακράς Βραχυπρόθεσμης Μνήμης (LSTM), τα οποία είναι εξαιρετικά αποτελεσματικά στην αναγνώριση χρονικών εξαρτήσεων. Η αρχιτεκτονική που υλοποιήθηκε αποτελείται από:

1. Ένα στρώμα εισόδου (Input) που δέχεται τα δεδομένα του παραθύρου ιστορικού.
2. Δύο διαδοχικά στρώματα LSTM (LSTM(64, return_sequences=True) και LSTM(32)). Η παράμετρος return_sequences=True στο πρώτο στρώμα είναι απαραίτητη για τη διασύνδεση των δύο LSTM.
3. Ένα πλήρως συνδεδεμένο στρώμα εξόδου (Dense) με νευρώνες ίσους με το πλήθος των τιμών προς πρόβλεψη.

4. Ένα στρώμα αναδιαμόρφωσης (Reshape) για την επαναφορά της εξόδου στο επιθυμητό σχήμα (timesteps, features).

Το μοντέλο εκπαιδεύτηκε με τον βελτιστοποιητή Adam και συνάρτηση απώλειας το Μέσο Απόλυτο Σφάλμα (MAE). Χρησιμοποιήθηκε η τεχνική EarlyStopping για την αποφυγή της υπερεκπαίδευσης, παρακολουθώντας την απόδοση στο σύνολο επικύρωσης.

Κεφάλαιο 4: Αποτελέσματα και Αξιολόγηση

4.1 Μετρικές Αξιολόγησης

Η απόδοση των μοντέλων αξιολογήθηκε με τις ακόλουθες μετρικές:

- **Mean Absolute Error (MAE):** Το μέσο απόλυτο σφάλμα. Είναι εύκολα ερμηνεύσιμο, καθώς εκφράζεται στις ίδιες μονάδες με την προβλεπόμενη τιμή.
- **Mean Absolute Percentage Error (MAPE):** Το μέσο απόλυτο ποσοστιαίο σφάλμα. Παρέχει μια σχετική μέτρηση του σφάλματος.
- **Root Mean Squared Error (RMSE):** Η ρίζα του μέσου τετραγωνικού σφάλματος. Δίνει μεγαλύτερη βαρύτητα στα μεγάλα σφάλματα.
- **R-squared (R^2):** Ο συντελεστής προσδιορισμού. Δείχνει το ποσοστό της διακύμανσης των πραγματικών τιμών που εξηγείται από το μοντέλο.

4.2 Αποτελέσματα Βραχυπρόθεσμης Πρόβλεψης (1 ώρα)

Ο Πίνακας 1 συνοψίζει την απόδοση του μοντέλου για την πρόβλεψη της επόμενης ώρας.

Αντιστροφή της κανονικοποίησης για προβλέψεις και πραγματικές τιμές...
Ολοκληρώθηκε η αντιστροφή.
Σχήμα πραγματικών τιμών (y_test_real): (17544, 12, 325)
Σχήμα προβλέψεων (predictions_real): (17544, 12, 325)

Υπολογισμός μετρικών αξιολόγησης ανά χρονικό ορίζοντα...
Ολοκληρώθηκε ο υπολογισμός των μετρικών.

===== ΑΠΟΤΕΛΕΣΜΑΤΑ ΑΞΙΟΛΟΓΗΣΗΣ – ΒΡΑΧΥΠΡΟΘΕΣΜΗ ΠΡΟΒΛΕΨΗ (1 ΩΡΑ) =====						
Οι τιμές αναγράφονται στη μορφή: Μέση Τιμή ± Τυπική Απόκλιση (για όλους τους αισθητήρες)						
	MAE	MAPE (%)	RMSE	R2		
t+5 min	2.818 ± 1.173	7.082 ± 4.431	5.297 ± 2.011	0.545 ± 0.288		
t+10 min	2.822 ± 1.178	7.062 ± 4.409	5.302 ± 2.006	0.544 ± 0.289		
t+15 min	2.822 ± 1.183	7.041 ± 4.395	5.306 ± 2.003	0.545 ± 0.286		
t+20 min	2.824 ± 1.182	7.020 ± 4.348	5.312 ± 1.994	0.546 ± 0.283		
t+25 min	2.834 ± 1.186	7.023 ± 4.334	5.333 ± 1.997	0.545 ± 0.280		
t+30 min	2.856 ± 1.190	7.050 ± 4.335	5.361 ± 2.006	0.543 ± 0.280		
t+35 min	2.875 ± 1.194	7.070 ± 4.321	5.391 ± 2.013	0.541 ± 0.276		
t+40 min	2.904 ± 1.199	7.112 ± 4.317	5.426 ± 2.019	0.539 ± 0.271		
t+45 min	2.937 ± 1.209	7.170 ± 4.332	5.473 ± 2.037	0.534 ± 0.268		
t+50 min	2.975 ± 1.220	7.241 ± 4.351	5.530 ± 2.057	0.527 ± 0.270		
t+55 min	3.014 ± 1.238	7.319 ± 4.385	5.589 ± 2.082	0.522 ± 0.263		
t+60 min	3.056 ± 1.254	7.411 ± 4.431	5.659 ± 2.113	0.514 ± 0.264		

Πίνακας 1: Αποτελέσματα αξιολόγησης για τη βραχυπρόθεσμη πρόβλεψη.

Ανάλυση: Όπως ήταν αναμενόμενο, η ακρίβεια του μοντέλου μειώνεται όσο αυξάνεται ο χρονικός ορίζοντας. Το MAE για την πρόβλεψη των επόμενων 5 λεπτών (t+5 min) είναι 2.818, ενώ για την πρόβλεψη σε 60 λεπτά (t+60 min) αυξάνεται σε 3.056. Αντίστοιχη φθίνουσα πορεία ακολουθεί και ο συντελεστής R^2 . Η τυπική απόκλιση των σφαλμάτων επίσης αυξάνεται, υποδεικνύοντας ότι η απόδοση του μοντέλου ποικίλλει περισσότερο μεταξύ των διαφορετικών αισθητήρων για μεγαλύτερους ορίζοντες.

4.3 Αποτελέσματα Μεσοπρόθεσμης Πρόβλεψης (12 ώρες)

Ο Πίνακας 2 παρουσιάζει την απόδοση για την ωριαία πρόβλεψη των επόμενων 12 ωρών.

=====					
===== ΑΠΟΤΕΛΕΣΜΑΤΑ ΑΞΙΟΛΟΓΗΣΗΣ - ΜΕΣΟΠΡΟΘΕΣΜΗ ΠΡΟΒΛΕΨΗ (12 ΩΡΕΣ) =====					
	MAE	MAPE (%)	RMSE	R^2	
t+1 h	3.361 ± 1.386	7.994 ± 4.658	5.942 ± 2.210	0.466 ± 0.285	
t+2 h	4.071 ± 1.653	9.321 ± 5.265	7.020 ± 2.699	0.317 ± 0.252	
t+3 h	4.782 ± 1.984	11.084 ± 6.238	8.147 ± 3.273	0.131 ± 0.216	
t+4 h	4.955 ± 2.060	11.266 ± 6.228	8.507 ± 3.473	0.057 ± 0.248	
t+5 h	4.700 ± 1.905	11.061 ± 6.289	8.120 ± 3.150	0.127 ± 0.227	
t+6 h	4.257 ± 1.685	10.638 ± 6.545	7.625 ± 2.964	0.203 ± 0.256	
t+7 h	4.032 ± 1.625	10.807 ± 6.955	7.503 ± 3.073	0.218 ± 0.289	
t+8 h	3.869 ± 1.598	10.878 ± 7.091	7.502 ± 3.156	0.214 ± 0.304	
t+9 h	3.802 ± 1.597	10.476 ± 6.853	7.354 ± 3.120	0.211 ± 0.336	
t+10 h	3.858 ± 1.601	10.293 ± 6.793	7.405 ± 3.125	0.219 ± 0.326	
t+11 h	4.203 ± 1.688	11.022 ± 6.999	7.839 ± 3.176	0.171 ± 0.257	
t+12 h	4.434 ± 1.813	11.802 ± 7.524	7.983 ± 3.177	0.153 ± 0.214	
=====					

Πίνακας 2: Αποτελέσματα αξιολόγησης για τη μεσοπρόθεσμη πρόβλεψη.

Ανάλυση: Τα σφάλματα εδώ είναι σημαντικά μεγαλύτερα σε σύγκριση με τη βραχυπρόθεσμη πρόβλεψη. Το MAE για την πρόβλεψη της επόμενης ώρας (t+1 h) είναι 3.361, ενώ για την 12η ώρα (t+12 h) εκτοξεύεται σε 4.434. Ο δείκτης R^2 για τους μακρινούς ορίζοντες είναι πολύ χαμηλός, υποδηλώνοντας ότι το μοντέλο δυσκολεύεται να συλλάβει τη δυναμική της κυκλοφορίας σε τόσο μεγάλο βάθος χρόνου, όπου απρόβλεπτοι παράγοντες (π.χ. ατυχήματα, καιρικές συνθήκες) παίζουν καθοριστικό ρόλο.

4.4 Συζήτηση Αποτελεσμάτων

Η σύγκριση των δύο σεναρίων καταδεικνύει τη θεμελιώδη πρόκληση της πρόβλεψης χρονοσειρών: η αβεβαιότητα αυξάνεται εκθετικά με τον χρόνο. Ενώ το μοντέλο LSTM είναι εξαιρετικά αποτελεσματικό στο να "θυμάται" τα μοτίβα της πρόσφατης κίνησης για βραχυπρόθεσμες προβλέψεις, η ικανότητά του να προβλέπει ώρες μπροστά είναι περιορισμένη, βασιζόμενο κυρίως στα γενικά εποχικά πρότυπα. Η μεγάλη τυπική απόκλιση των σφαλμάτων υποδηλώνει ότι η γεωγραφική θέση και τα ιδιαίτερα χαρακτηριστικά κάθε αισθητήρα (π.χ. αν βρίσκεται σε αυτοκινητόδρομο ή σε αστικό δρόμο) επηρεάζουν σημαντικά την απόδοση.

Κεφάλαιο 5: Συμπεράσματα και Μελλοντικές Επεκτάσεις

Η παρούσα εργασία επέδειξε επιτυχώς τη διαδικασία κατασκευής ενός μοντέλου βαθιάς μάθησης για την πρόβλεψη κυκλοφοριακής ταχύτητας. Το μοντέλο LSTM που αναπτύχθηκε πέτυχε ικανοποιητική απόδοση, ιδίως στο σενάριο της βραχυπρόθεσμης πρόβλεψης, καθιστώντας το ένα χρήσιμο εργαλείο για εφαρμογές πραγματικού χρόνου. Ταυτόχρονα, τα αποτελέσματα της μεσοπρόθεσμης πρόβλεψης ανέδειξαν τους περιορισμούς των μοντέλων που βασίζονται αποκλειστικά σε ιστορικά δεδομένα ταχύτητας.

Για μελλοντική βελτίωση, θα μπορούσαν να διερευνηθούν οι ακόλουθες κατευθύνσεις:

- **Ενσωμάτωση Πολυμεταβλητών Δεδομένων:** Χρήση εξωτερικών δεδομένων, όπως καιρικές συνθήκες, πληροφορίες για ατυχήματα ή προγραμματισμένες εκδηλώσεις.
- **Χωρικές Συσχετίσεις:** Αξιοποίηση της τοπολογίας του οδικού δικτύου. Μοντέλα όπως τα Graph Neural Networks (GNNs) είναι ιδανικά για να συλλαμβάνουν ταυτόχρονα τις χρονικές και τις χωρικές εξαρτήσεις (π.χ. πώς η κίνηση σε έναν αισθητήρα επηρεάζει τους γειτονικούς του).

- **Προηγμένες Αρχιτεκτονικές:** Δοκιμή πιο σύγχρονων αρχιτεκτονικών, όπως τα Transformers, τα οποία έχουν δείξει εξαιρετικά αποτελέσματα σε προβλήματα ακολουθίας.
- **Βελτιστοποίηση Υπερπαραμέτρων:** Συστηματική αναζήτηση των βέλτιστων υπερπαραμέτρων του μοντέλου (π.χ. αριθμός στρωμάτων, νευρώνων, learning rate).

Βιβλιογραφία

Li, Y., Yu, R., Shahabi, C., & Liu, Y. (2018). Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting. *In Proceedings of the International Conference on Learning Representations (ICLR)*.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536.

Abadi, M., et al. (2016). TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems. *arXiv preprint arXiv:1603.04467*.

McKinney, W. (2010). Data Structures for Statistical Computing in Python. *In Proceedings of the 9th Python in Science Conference (SciPy 2010)*, 56-61.
